Machine Learning Engineering Tech Challenge

Resumen

El objetivo de este reto es construir una Plataforma de Machine Learning, capaz de gestionar el entrenamiento de modelos bajo demanda y flujos de predicción programados o bajo demanda. Se deben registrar experimentos, modelos y predicciones.

Se te proporcionará un conjunto de datos tabular estándar en formato CSV. Tu tarea es diseñar e implementar un sistema que automatice el ciclo de vida de un modelo de machine learning, desde el entrenamiento hasta la persistencia de la inferencia.

Arquitectura del Sistema y Requisitos

Tu solución debe ser completamente autónoma y ser ejecutable en una máquina local utilizando un único comando de orquestación (por ejemplo, make start). El sistema debe estar dividido en componentes distintos y desacoplados:

1. Motor de Orquestación de Flujos de Trabajo

Debes implementar un motor de flujos de trabajo (*workflow engine*) para gestionar dos pipelines de datos principales:

- **Pipeline de Entrenamiento:** Un flujo de trabajo asíncrono o bajo demanda que ingeste los datos del CSV, ejecute la ingeniería de características (*feature engineering*), divida los datos, entrene un modelo predictivo y evalúe su rendimiento.
- **Pipeline de Inferencia:** Un flujo de trabajo que pueda ser activado bajo demanda para extraer el último modelo "ganador", ingestar un nuevo lote de características (o un conjunto de prueba), generar predicciones y pasarlas a la capa de almacenamiento.

2. Seguimiento de Experimentos y Registro de Modelos

Cada vez que se ejecute el pipeline de entrenamiento, el sistema debe registrar:

- Los hiperparámetros utilizados para el entrenamiento.
- Las métricas de evaluación (ej. precisión, F1-score, RMSE, dependiendo del modelo que elijas).
- El artefacto del modelo entrenado resultante.

El sistema debe identificar automáticamente si el modelo recién entrenado tiene un mejor rendimiento que las iteraciones anteriores. Si es así, debe etiquetar o registrar este modelo como la versión actual lista para producción.

3. Almacenamiento de Artefactos

Los artefactos de los modelos no pueden simplemente vivir en la memoria volátil local donde se despliega la solución. Tu sistema debe desplegar un servicio de almacenamiento de objetos local (por ejemplo simulando un *bucket* de almacenamiento en la nube). Los modelos ganadores del pipeline de entrenamiento deben guardarse sistemáticamente en este *bucket*.

4. Capa de Base de Datos

Todas las predicciones generadas por el Pipeline de Inferencia deben guardarse en un sistema de gestión de base de datos relacional estructurado.

El esquema de la base de datos debe incluir al menos: `prediction_id`, `timestamp` y el valor de la predicción (`predicted_value`).

Entregables

1. **Código Base:** Código en Python que sea limpio, estructurado y modular.
2. **Infraestructura como Código (IaC):** Los archivos de configuración necesarios para levantar toda la red de servicios (bases de datos, orquestadores, servidores de seguimiento de experimentos y *buckets* de almacenamiento) de forma local.
3. **Documentación (`README.md`):**
   - Instrucciones claras sobre cómo iniciar el sistema.
   - Cómo ejecutar o lanzar una tarea de entrenamiento y una de inferencia.
   - Un breve resumen de tus elecciones arquitectónicas y una explicación de cómo escalarías este sistema en un entorno en la nube (*cloud*).

Notas Importantes

Somos conscientes de que este reto es complejo y requiere un volumen considerable de trabajo. Te recomendamos que completes todo lo que te sea posible dentro del tiempo que tengas disponible.

Si te atascas con un componente específico o una herramienta se resiste, **preferimos que sigas adelante con otras partes de la solución** en lugar de quedarte bloqueado. Si esto ocurre, simplemente deja un comentario en tu `README.md` explicando qué falló, cómo lo solucionarías con más tiempo y continúa con el siguiente bloque de la arquitectura. Valoramos más ver cómo integras el panorama general que la perfección en un solo detalle.